

宇宙大規模構造のデータ解析から 産業データ活用へ

日影千秋 (野村総合研究所)

Contents

1. 宇宙大規模構造のデータ解析

- ① ジーナス統計による宇宙論
- ② フーリエ位相から探る宇宙論
- ③ ミンコフスキー汎関数による初期ゆらぎの非ガウス性の制限

2. 産業データ分析

- ① 需要予測モデルの開発
- ② 検索システムの精度改善
- ③ 生成AIの軽量化
- ④ 自動運転におけるロングテール問題


1. 宇宙大規模構造のデータ解析 教授との共著論文

	論文名	出版先
1	Three-Dimensional Genus Statistics of Galaxies in the SDSS Early Data Release	2002PASJ54..707H
2	The Distribution Function of the Phase Sum as a Signature of Phase Correlations Induced by Nonlinear Gravitational Clustering	2004ApJ...600..553H
3	Fourier Phase Analysis of SDSS Galaxies	2005PASJ...57..709H
4	Topology Analysis of the Sloan Digital Sky Survey. I. Scale and Luminosity Dependence	2005ApJ...633...11P
5	Primordial Non-Gaussianity and Analytical Formula for Minkowski Functionals of the Cosmic Microwave Background and Large-Scale Structure	2006ApJ...653...11H
6	Large-Scale Anisotropic Correlation Function of SDSS Luminous Red Galaxies	2008ApJ...676..889O
7	Limits on primordial non-Gaussianity from Minkowski Functionals of the WMAP temperature anisotropies	2008MNRAS.389.1439H
8	Limits on isocurvature perturbations from non-Gaussianity in WMAP temperature anisotropy	2009MNRAS.398.2188H
9	Limits on second-order non-Gaussianity from Minkowski functionals of WMAP 7-year data	2012MNRAS.425.2187H
10	The Subaru FMOS galaxy redshift survey (FastSound). I. Overview of the survey targeting H α emitters at $z \sim 1.4$	2015PASJ...67...81T
11	The Subaru FMOS galaxy redshift survey (FastSound). IV. New constraint on gravity theory from redshift space distortions at $z \sim 1.4$	2016PASJ...68...38O
12	Minkowski functionals and the nonlinear perturbation theory in the large-scale structure: Second-order effects	2022PhRvD.105b3527M

1-1. ジーナス統計による宇宙論

ジーナス統計

- 修論テーマはSDSSサーベイへの応用を見据えた宇宙大規模構造のトポロジーの定量化



1-1. ジーナス統計による宇宙論

ジーナス統計の理論式

- Matsubara 1994は弱い非ガウス場におけるジーナス統計の摂動論的な公式を導出
- 理論式をベースに観測データの解釈が可能となった


$$G_{2nd}(\nu) = -\frac{e^{-\frac{\nu^2}{2}}}{(2\pi)^2} \left(\frac{\sigma_1^2}{3\sigma^2} \right)^{\frac{3}{2}} \left[H_2(\nu) + \sigma \left(\frac{S}{6} H_5(\nu) + \frac{3T}{2} H_3(\nu) + 3U H_1(\nu) \right) + \mathcal{O}(\sigma^2) \right]$$

In the above expression, $H_n(\nu) \equiv (-)^n e^{\nu^2/2} (d/d\nu)^n e^{-\nu^2/2}$ is the n -th order Herm polynomial, and S , T , and U are defined as

$$S = \frac{1}{\sigma^4} \langle \delta^3 \rangle,$$

$$T = -\frac{1}{2\sigma_1^2 \sigma^2} \langle \delta^2 \nabla^2 \delta \rangle,$$

$$U = -\frac{3}{4\sigma_1^4} \langle \nabla \delta \cdot \nabla \delta \nabla^2 \delta \rangle,$$





Matsubara 1994, "Analytic Expression of the Genus in a Weakly Non-Gaussian Field Induced by Gravity"

1-1. ジーナス統計による宇宙論

SDSS銀河分布のジーナス統計による宇宙論

- SDSS銀河データを使って、ジーナス統計やミンコフスキー汎関数による宇宙大規模構造のトポロジー、形状を定量化し、宇宙モデルの選別に利用



1-2. フーリエ位相から探る宇宙論


フーリエ位相と非ガウス性

- ゆらぎは振幅と位相から成る

$$f_{\mathbf{k}} = |f_{\mathbf{k}}| \exp(i\theta_{\mathbf{k}}).$$

- 振幅のスケールごとの強さを表すパワースペクトルを使った統計量が一般的
- 位相を使った統計量は確立しておらず、未開拓の領域だった
- Matsubara 2003で位相のみを使った統計量を発案

$$\theta_{\mathbf{k}_1} + \cdots + \theta_{\mathbf{k}_N}$$




1-2. フーリエ位相から探る宇宙論


SDSS銀河分布のフーリエ位相分析

- SDSSの銀河分布における位相の解析を通じて、観測された銀河構造が Λ CDMモデルの予測と一致
- 宇宙の構造形成シナリオを従来のパワー・スペクトルを補完する「位相」の視点から裏付け

Scale dependence



Angle dependence



1-3. ミンコフスキー汎関数による初期ゆらぎの非ガウス性の制限

ミンコフスキー汎関数

- ・ ガウシアン分布

$$V_k^{(G)}(\nu) = A_k \exp\left(-\frac{\nu^2}{2}\right) H_{k-1}(\nu)$$

- ・ 1次の摂動 (Matsubara 2003)


$$v_k^{(1)}(\nu) = \frac{S}{6} H_{k+2}(\nu) - \frac{S_I}{2} H_k(\nu) - \frac{S_{II}}{2} H_{k-2}(\nu)$$

- ・ 2次の摂動 (Matsubara 2010)

$$v_0^{(2)}(\nu) = \frac{S^2}{72} H_5(\nu) + \frac{K}{24} H_3(\nu),$$

$$v_1^{(2)}(\nu) = \frac{S^2}{72} H_6(\nu) + \frac{K - SS_I}{24} H_4(\nu) - \frac{1}{12} \left(K_I + \frac{3}{8} S_I^2 \right) H_2(\nu) - \frac{K_{III}}{8},$$

$$v_2^{(2)}(\nu) = \frac{S^2}{72} H_7(\nu) + \frac{K - 2SS_I}{24} H_5(\nu) - \frac{1}{6} \left(K_I + \frac{1}{2} SS_{II} \right) H_3(\nu) - \frac{1}{2} \left(K_{II} + \frac{1}{2} S_I S_{II} \right) H_1(\nu).$$




Surface area V0
Circumference V1
Euler Characteristic V2

1-3. ミンコフスキー汎関数による初期ゆらぎの非ガウス性の制限

CMBのミンコフスキー汎関数

- WMAPのモックシミュレーションデータでの検証




出典: Hikage et al. 2006 "Primordial Non-Gaussianity and Analytical Formula for Minkowski Functionals of the Cosmic Microwave Background and Large-Scale Structure"

1-3.ミンコフスキー汎関数による初期ゆらぎの非ガウス性の制限

初期ゆらぎの非ガウス性の制限

- WMAP衛星のCMB観測データミンコフスキー汎関数で分析し、宇宙の初期ゆらぎの非ガウス性を制限
- 1次の非ガウス性 f_{NL} に加え、2次の非ガウス性 g_{NL} , τ_{NL} も含めて制限

Estimator	band	$f_{\text{NL}}^{(\text{loc})}$	$f_{\text{NL}}^{(\text{eq})}$	$f_{\text{NL}}^{(\text{act})}$	$\tau_{\text{NL}}/10^4$	$g_{\text{NL}}/10^5$
MFs	V+W	20 ± 42	-121 ± 208	-129 ± 171	-7.5 ± 8.7	-1.9 ± 6.4
	Q+V+W	22 ± 43	-185 ± 211	-216 ± 172	-10.6 ± 8.9	-1.9 ± 6.3
	Q	21 ± 45	-5 ± 264	-94 ± 178	-7.5 ± 10.8	-4.4 ± 6.9
	V	33 ± 43	-61 ± 220	-143 ± 174	-6.5 ± 9.4	-2.7 ± 6.7
	W	12 ± 44	-102 ± 219	-98 ± 174	-7.5 ± 10.8	-4.4 ± 6.9




1. 宇宙大規模構造のデータ解析


観測データから構造を捉える

- さまざまな統計量を使って、データの背後にある構造を捉える研究を行ってきた

データ




WMAP




SDSS


特徴量抽出



情報抽出



Okumura, Hikage+ 2016



Hikage+ 2018

2. 産業データ分析

産業データ分析

- 産業データ分析はデータの種類や目的は大きく違う
- 限られたデータから構造を捉え、有用な情報を引き出す点は宇宙論研究に限らず、産業データ分析にも適用できる技術

	宇宙論研究	産業データ分析
データ	銀河サーベイ、CMB	販売履歴、顧客行動、テキスト、センサー
構造	フィラメント、ボイド	需要パターン、行動パターン、意味空間、
手法	パワースペクトル、ジーナス統計、ミンコフスキー汎関数、位相統計	機械学習、埋め込みモデル
比較・検証の基準	理論モデル、シミュレーション	業務仮説、施策
目的	宇宙論パラメータ、初期ゆらぎなど	意思決定・課題解決につながる知見

2. 産業データ分析

産業データ分析（生成AI利用なし）

- さまざまな業種で課題解決・意思決定支援のための業務データの分析を行う


業種	データ	分析テーマ
出版	書誌情報、販売実績(POS)データ	書籍の売上冊数の予測モデルの開発
小売	商品情報、販売実績(POS)データ	新規発売商品の販売予測モデルの開発
鉄鋼流通	在庫・配送・販売実績	在庫・廃棄・物流コスト・配送経路の最適化
通信サービス	会員・利用ログ	入会促進・退会抑止・提携小売店舗への送客の施策効果分析
宅配サービス	会員・購買・利用履歴	宅配停止要因分析、離反予測モデルの開発
物流	輸配送・在庫・出荷実績	輸配送および在庫コストの可視化、コスト要因分析
電力	蓄電池検査データ	劣化予測、設備保全高度化
卸売	在庫・物流・販売実績	在庫・物流・販売データ分析による利益改善
通信×小売	顧客属性・アプリ利用・ 購買実績	異業種連携の連合学習モデルの開発
小売	商品データ、ユーザーのクエリ	商品検索システムの精度・性能の改善

2-1. 需要予測モデルの開発


出版業界の課題

- 出版業界では需要を読み誤ると、返本・廃棄と欠品による機会損失が発生

① 需要予測と初版部数のバランス図



② 出版フロー図




2-1. 需要予測モデルの開発

需要予測モデル

- 産業データでは一般に理論モデルが存在しない中で需要パターンを学習し推定する必要がある
- 機械学習による実需予測を提供するシステムを構築し、意思決定をサポート

需要予測モデルの全体フロー（クラウド上での定期的な処理）



2-1. 需要予測モデルの開発 業務運用への壁


- 機械学習モデルにおいて精度改善は達成できた一方で、データの欠損、顧客の期待値コントロール、説明可能性、コストなど業務で運用していく上でさまざまなハードルがある



2-2. 検索システムの精度改善

商品検索システム


- クエリに対して関連度の高い商品をピックアップするシステム
- ①キーワード検索(語句の一致)と②ベクトル検索(意味の近さ)を組み合わせるハイブリッド検索が一般的
- 網羅的かつ関連性の高い検索結果を実現できる
- 表記ゆれや、似て非なる商品をどう排除するかが課題



2-2. 検索システムの精度改善

埋め込みとベクトル検索

- ・ 単語や文章などのテキストを低次元のベクトル空間に写像
- ・ テキストをどうマッピングするかが課題




意味が近いテキストほど、埋め込み空間上で近くに配置される

2-2. 検索システムの精度改善

ハードネガティブサンプリングによる追加学習


- ・ 語や文脈は近いが検索意図として外れているものをどう区別するか課題
 - ・ 例: ノンアルコールビールとビール、純正インク vs 互換インク
- ・ ハードネガティブ(似ているが間違い)を負例として追加学習することで、以前は混同していた概念が、明確に分離したクラスターとして認識される



2-2. 検索システムの精度改善

埋め込み空間のトポロジー

- 検索精度改善は、単なる距離最適化ではなく、意味空間の構造を再配置する問題
- 埋め込み空間のトポロジーをpersistent homologyなどの統計量を使った研究もある



UMAPという手法を用いて、多次元のトポロジカル・シグネチャを2次元平面に圧縮してプロット。検索されやすい文書（High retrievability）と検索されにくい文書（Low retrievability）が、トポロジー空間上で明確に異なるクラスター（集団）を形成




Figure 16. Clustering of Unified Topological Signatures and their normalized Recall@100.

27種類のモデルから生成された何百もの埋め込み空間を、UTSに基づいて2次元にマップ。赤に近いほど検索精度(Recall@100)が高いモデルであることを示す。

2. 産業データ分析

産業データ分析 (生成AIを活用)


- 生成AIで分析業務の高度化と効率化を推進するテーマも担当

領域	分析テーマ
検索・生成AI	クエリに対応するテーブル検索、SQLコード生成AIの精度改善
生成AI	量子化によるモデルの軽量化、Local LLM活用
生成AI	SLM(小規模言語モデル)の業務活用
エージェント	市場調査業務自動化のためのAIエージェントの開発
RAG	回答精度向上のためドメイン辞書登録システムの自動化
自動運転	自動運転モデルのロングテール課題解決に向けた取り組み

2-3. 生成AIの軽量化

量子化


- 生成AIモデルは大規模化により性能が向上した一方で、GPUメモリや推論コストが実運用上の制約となる
- 量子化はモデルの重みや演算を低精度に変換することで、メモリ使用量や計算負荷を減らす技術



2-3. 生成AIの軽量化

量子化レベルと精度のトレードオフ

- 低bit化でサイズは減るが4-bitを下回ると精度劣化が大きい
- 量子化ではモデルを軽くする際にどの情報を残すかが課題



出典: Jin et al. "A Comprehensive Evaluation of Quantization Strategies for Large Language Models" (arXiv: 2402.16775)

2-3. 生成AIの軽量化

AWQ - Activation Aware Weight Quantization

- ・ 実データ入力時に強く活性化するモデル出力に強く影響する重みだけを重点的に保護し、それ以外を強く量子化する手法
- ・ 約1%の重要なモデルの重みを保護することで、低bit量子化による精度劣化を抑えられる




PPL ↓	FP16	RTN (w3-g128)	FP16% (based on act.)			FP16% (based on W)			FP16% (random)		
			0.1%	1%	3%	0.1%	1%	3%	0.1%	1%	3%
OPT-1.3B	14.62	119.00	25.03	16.91	16.68	108.71	98.55	98.08	119.76	109.38	61.49
OPT-6.7B	10.86	23.54	11.58	11.39	11.36	23.41	22.37	22.45	23.54	24.23	24.22
OPT-13B	10.13	46.04	10.51	10.43	10.42	46.07	48.96	54.49	44.87	42.00	39.71

2-3. 生成AIの軽量化

1-bit量子化


- LLMを極限まで軽量化しつつ性能を保てるかを問う、最近注目の研究テーマ
- Microsoft BitNetでは $(-1, 0, 1)$ の3値 (1.58bit) の量子化
- 学習中から重みを低bit化する前提で最適化
- 重要な重み・外れ値・活性化は守りながら、重みの大部分を極限まで離散化



2-4. 自動運転

自動運転


- 自動運転は一部地域で実用化が進む一方、天候・道路環境・人間行動などの複雑性が残る



2-4. 自動運転

ロングテール問題


- 自動運転では、まれにしか起きない危険場面への対応が安全性を左右する
- 100%の運転に近づくほどコストが高く、どこで線引するかが課題



2-4. 自動運転

NVIDIAの自動運転統合プラットフォーム

- NVIDIAは基盤モデル・物理PF・評価PFの組合せが研究基盤を整備、OSS化している




NVIDIA は、シミュレーション・生成 AI・物理 AI・大規模学習基盤を統合し、自動運転の開発をエンドツーエンドで加速するプラットフォームを提供

2-4. 自動運転

ワールドモデル

- 宇宙構造形成が初期条件から宇宙の時間発展を記述してきたように、自動運転でも観測から世界の状態遷移を内部モデルとして学習する方向へ進んでいる。



引用: Hu et al. "Planning-oriented Autonomous Driving (arXiv;2212.10156)

自分の車だけでなく、周辺車両・歩行者・道路環境を含む「運転世界」全体の状態遷移を内部で予測することで、安全な行動を選択できるという考え方

まとめ

- 天文研究と産業応用では扱うデータや目的は異なるが、限られた観測データから構造を読み解き、仮説を立てて意思決定をするという点で共通点が多い
- ビジネスとしてデータ利活用を進めるには、モデルの精度だけでなく、データ品質の担保、顧客の期待値コントロール、費用対効果のある施策への接続が必要
- 物理AIやワールドモデルなど、物理法則・状態遷移・不確実性の理解をデータ駆動モデルに組み込む動きが広がっており、物理的な考え方が産業領域でも生きる場面がある